# Алгоритмы извлечения сигнала из временных рядов с использованием метода Monte Carlo SSA

Потешкин Егор Павлович, гр.24.М22-мм

Санкт-Петербургский государственный университет
Математическое моделирование, программирование и искусственный интеллект
Кафедра статистического моделирования

Санкт-Петербург, 2026

# Введение

$\mathsf{X} = (x_1, \ldots, x_N)$ — временной ряд длины $N$.

Модель: $\mathsf{X} = \mathsf{T} + \mathsf{P} + \mathsf{R}$, где $\mathsf{T}$ — тренд, $\mathsf{P}$ — периодическая компонента и $\mathsf{R}$ — шум, случайная составляющая.

Проблема: Как автоматически выделить сигнал $\mathsf{S} = \mathsf{T} + \mathsf{P}$?

Методы:

1. Singular spectrum analysis (SSA) [Broomhead and King, 1986], [Golyandina, Nekrutkin and Zhigljavsky, 2001] для выделения сигнала $\mathsf{S}$.
2. Monte Carlo SSA (MC-SSA) [Allen and Smith, 1996] для проверки гипотезы $H_0 : \mathsf{S} = 0$.

Но: один из шагов SSA требует визуального анализа для определения сигнальных компонент, необходима автоматизация этого шага.

# Введение. Продолжение

Существует метод автоматического выделения тренда и периодик [Golyandina, Dudnik and Shlemov, 2025].

Недостаток: метод работает только если компоненты доминируют над шумом.

Основная цель работы: разработать метод автоматического выделения сигнала, который не обязательно доминирует над шумом.

Данный метод будет основан на методе MC-SSA для обнаружения сигнала и SSA его выделения, поэтому работа выстроена следующим образом:

1. Описание методов SSA и MC-SSA.
2. Исследование выбора проекционных векторов в методе MC-SSA.
3. Применение метода MC-SSA на практике.
4. Описание существующего метода автоматической идентификации.
5. Описание разработанного метода автоматической идентификации и его численное сравнение с существующим методом.

# Глава 1. Метод MC-SSA

# Обозначения и известные результаты: Метод SSA

Входные данные: временной ряд $\mathsf{X} = (x_1, \ldots, x_N)$.

Параметр: длина окна $L$, $1 < L < N$.

Результат: $m$ восстановленных составляющих временного ряда.

1. **Вложение**: $\mathbf{X} = \mathcal{T}(\mathsf{X}) = [X_1 : \ldots : X_K]$, где $X_i = (x_1, \ldots, x_{i+L-1})^{\mathrm{T}}$, $K = N - L + 1$.
2. **Разложение**: $\mathbf{X} = \sum_{i=1}^{r} \sigma_i P_i Q_i^{\mathrm{T}} = \mathbf{X}_1 + \ldots + \mathbf{X}_r$, $\operatorname{rank} \mathbf{X}_i = 1$.
3. **Группировка**: $\mathbf{X} = \mathbf{X}_{I_1} + \ldots + \mathbf{X}_{I_m}$, где $\mathbf{X}_{I_k} = \sum_{i \in I_k} \mathbf{X}_i$.
4. **Восстановление**: $\mathsf{X} = \widetilde{\mathsf{X}}_{I_1} + \ldots + \widetilde{\mathsf{X}}_{I_m}$, где $\widetilde{\mathsf{X}}_{I_k} = \mathcal{T}^{-1} \circ \mathcal{H}(\mathbf{X}_{I_k})$.

# Обозначения и известные результаты: Toeplitz SSA

Модификации SSA отличаются только шагом разложения.

Basic SSA: сингулярное разложение траекторной матрицы, универсальный метод.

Toeplitz SSA: теплицево разложение траекторной матрицы, имеет преимущество для стационарных рядов:

$$\mathbf{X} = \sum_{i=1}^{L} \sigma_i P_i Q_i^{\mathrm{T}} = \mathbf{X}_1 + \ldots + \mathbf{X}_L,$$

где $Q_i = \mathbf{X}^{\mathrm{T}} P_i / \sigma_i$, $\sigma_i = \|\mathbf{X}^{\mathrm{T}} P_i\|$, $\{P_i\}_{i=1}^{L}$ — собственные векторы матрицы $\mathbf{T}$ с элементами

$$t_{ij} = \frac{1}{N - |i-j|} \sum_{m=1}^{N-|i-j|} x_m x_{m+|i-j|}, 1 \leqslant i, j \leqslant L.$$

# Обозначения и известные результаты: Multiple Monte Carlo SSA [Golyandina, 2023]

Модель: $\mathsf{X} = \mathsf{S} + \boldsymbol{\xi}$, где $\mathsf{S}$ — сигнал (колебания с какой-то частотой), $\boldsymbol{\xi}$ — стационарный процесс с нулевым средним.

Задача: проверить $H_0 : \mathsf{S} = 0$ — отсутствие сигнала.

Метод: Multiple Monte Carlo SSA [Golyandina, 2023] (далее просто MC-SSA).

Входные данные: временной ряд $\mathsf{X}$.
Параметры: длина окна $L$, выбор векторов $W_1, \ldots, W_H \in \mathbb{R}^L$, модель шума $\boldsymbol{\xi}$, количество суррогатных реализаций $G$.

1. Строятся статистики критерия $\widehat{p}_k = \|\mathbf{X}^{\mathrm{T}} W_k\|^2$, $k = 1, \ldots, H$.
2. Оцениваются их распределения на основе $G$ суррогатных реализаций $\boldsymbol{\xi}$.
3. Строятся предсказательные интервалы с поправкой на множественные сравнения с уровнем доверия $(1 - \alpha)$.

# Обозначения и известные результаты: поправка неточных критериев

Приведем алгоритм, преобразовывающий неточный критерий (консервативный или радикальный) в асимптотически точный.

Зафиксируем $H_0$, уровень значимости $\alpha^*$, количество выборок $M$ для оценки $\alpha_I(\alpha)$ и их объем $N$:

1. Моделируется $M$ выборок объема $N$ при верной $H_0$.
2. По моделированным данным строится зависимость ошибки первого рода от уровня значимости $\alpha_I(\alpha)$.
3. Рассчитывается формальный уровень значимости: $\widetilde{\alpha}^* = \alpha_I^{-1}(\alpha^*)$. Критерий с таким уровнем значимости является асимптотически точным при $M \to \infty$.

# Обозначения и известные результаты: выбор векторов для проекции в методе MC-SSA

Одним из параметров MC-SSA является выбор векторов $W_k$, на которые будет производится проекция столбцов матрицы $\mathbf{X}$.

Наиболее распространенный вариант MC-SSA использует векторы $W_k$, являющимися собственными векторами матрицы $\mathbf{X}\mathbf{X}^{\mathrm{T}}$ или $\mathbf{T}$ (далее будем называть его критерием «ev»).

Плюс: если $H_0$ отверглась, можно восстановить сигнал с помощью SSA на основе значимых $W_k$.

Минус: этот вариант дает радикальный критерий и преобразование его в точный — очень трудоемкая задача.

# Обозначения и известные результаты: выбор векторов для проекции в методе MC-SSA

Можно использовать косинусы в качестве векторов для проекции (далее критерий «cos»):

$$V_k = \begin{pmatrix} \cos(2\pi\omega_k 1) \\ \dots \\ \cos(2\pi\omega_k L) \end{pmatrix}, \quad W_k = \frac{V_k}{\|V_k\|}, \quad k = 1, \dots, L,$$

где $\omega_k = k/(2L)$.

Мотивация: собственные векторы стационарного процесса представляют собой гармоники с равноотстоящими частотами.

Плюс: такой критерий является точным.

Задача: сравнить критерий «cos» с критерием «ev» по мощности.

# Численное сравнение критериев MC-SSA

Модель: $\mathsf{X} = \mathsf{S} + \boldsymbol{\xi}$, где

1. $\mathsf{S} = \{Ae^{\alpha n}\cos(2\pi n\omega)\}_{n=1}^{N}$ — экспоненциально-модулированная гармоника.
2. $\boldsymbol{\xi}$ — стационарный процесс с известными параметрами.

Задача: сравнить ошибку первого рода и мощность критериев при различных вариантах сигнала S:

1. $a = 0,\ L\omega$ — целые;
2. $a = 0,\ L\omega$ — нецелые;
3. $a \neq 0,\ L\omega$ — целые;
4. $a = 0,\ L\omega$ — нецелые.

# Численное сравнение критериев MC-SSA: ошибка первого рода

Таблица: Ошибка первого рода при уровне значимости $\alpha^* = 0.1$

| | $L = 10$ | $L = 20$ | $L = 50$ | $L = 80$ | $L = 90$ |
|---|---|---|---|---|---|
| Собственные векторы $\mathbf{X}\mathbf{X}^{\mathrm{T}}$ | 0.087 | 0.133 | 0.387 | 1 | 1 |
| Собственные векторы $\mathbf{T}$ | 0.083 | 0.116 | 0.21 | 0.599 | 0.626 |
| Косинусы | 0.097 | 0.101 | 0.103 | 0.096 | 0.107 |

Вывод: для векторов $W_k$, порожденных исходным рядов, критерий MC-SSA радикален для $L > 10$, для косинусов критерий точен для любой длины окна.

# Численное сравнение критериев MC-SSA: мощность

Таблица: Мощность поправленных критериев при уровне значимости $\alpha^* = 0.1$

| $a = 0$, $L\omega$ — целые | $L = 10$ | $L = 20$ | $L = 50$ | $L = 80$ | $L = 90$ |
|---|---|---|---|---|---|
| Проекция на собственные векторы $\mathbf{T}$ | 0.424 | 0.484 | 0.525 | 0.582 | 0.646 |
| Проекция на косинусы | 0.543 | 0.546 | 0.546 | 0.614 | 0.646 |
| $a = 0$, $L\omega$ — нецелые | $L = 10$ | $L = 20$ | $L = 50$ | $L = 80$ | $L = 90$ |
| Проекция на собственные векторы $\mathbf{T}$ | 0.349 | 0.432 | 0.425 | 0.497 | 0.537 |
| Проекция на косинусы | 0.475 | 0.431 | 0.403 | 0.505 | 0.488 |
| $a \neq 0$, $L\omega$ — целые | $L = 10$ | $L = 20$ | $L = 50$ | $L = 80$ | $L = 90$ |
| Проекция на собственные векторы $\mathbf{X}\mathbf{X}^{\mathrm{T}}$ | 0.329 | 0.303 | 0.307 | – | – |
| Проекция на косинусы | 0.480 | 0.347 | 0.163 | 0.228 | 0.299 |
| $a \neq 0$, $L\omega$ — нецелые | $L = 10$ | $L = 20$ | $L = 50$ | $L = 80$ | $L = 90$ |
| Проекция на собственные векторы $\mathbf{X}\mathbf{X}^{\mathrm{T}}$ | 0.298 | 0.306 | 0.282 | – | – |
| Проекция на косинусы | 0.469 | 0.302 | 0.157 | 0.209 | 0.249 |

Вывод: критерий «cos» является более предпочтительным, поскольку является точным и по мощности не уступает, а в некоторых случаях даже превосходит критерий «ev».

# Применение MC-SSA к реальным временным рядам

- До этого предполагалось, что параметры шума $\xi$ известны.
- В реальности они неизвестны и их нужно оценивать. Тогда перед алгоритмом MC-SSA необходимо оценить параметры модели $\xi$ по исходному ряду.
- Также для критерия MC-SSA обычно используется модель красного шума (AR(1)), однако в геофизике, гидрологии и финансах ряды часто обладают длинной памятью.
- Неправильно выбранная модель делает критерий радикальным либо консервативным. Первое влечет за собой неприменимость критерия, а второе — уменьшение мощности критерия.
- На данный момент в работе преимущественно используется модель красного шума, однако в дальнейшем планируется добавить больше исследований рядов с длинной памятью.

# Обозначения и известные результаты: процессы с длинной памятью

**Определение**

*Говорят, что стационарный процесс $\xi$ обладает* ***длинной*** *памятью, если*

$$\sum_{h=0}^{H} |\gamma(h)| \to \infty,$$

*при $H \to \infty$. Иначе говорят, что $\xi$ обладает* ***короткой*** *памятью.*

Пример процесса с короткой памятью: процесс ARMA$(p, q)$.

Пример процесса с длинной памятью: процесс ARFIMA$(p, d, q)$:

$$Y_t = (1 - L)^{-d} X_t, \quad d < 1/2,$$

где $X_t$ — модель ARMA$(p, q)$.

# Численное исследование: оценка параметров шума

Модель: $\mathsf{X} = \boldsymbol{\xi}$, где $\boldsymbol{\xi}$ — модель AR$(1)$, ARFIMA$(0, d, 0)$ или ARFIMA$(1, d, 0)$.

Задача: сравнить точность различных методов оценки параметров шума $\boldsymbol{\xi}$ для разных длин ряда $N$.

Методы: MLE (с известным средним $\mu$ и его оценкой $\hat{\mu} = \bar{x}$), аппроксимация MLE [Haslett and Raftery, 1989] и метод Уиттла [Whittle, 1953].

Результат: численные эксперименты показали, что для реальных рядов с неизвестным средним метод Уиттла дает наименее смещенную оценку и обладает наименьшей вычислительной сложностью $O(N \log N)$ благодаря использованию FFT периодограммы.

# Модификация MC-SSA по части спектра

- Можно убрать неинтересующую нас часть спектра, задав диапазоны нерассматриваемых частот $\mathcal{B} = \bigcup_j [\omega_{j_1}, \omega_{j_2}]$.
- Таким образом, в алгоритме MC-SSA из рассмотрения уйдут все векторы $W_k$, частота $\omega_k$ которых попадает в $\mathcal{B}$.
- Оценка параметров по части спектра возможна с помощью правдоподобия Уиттла по части спектра (еще один плюс этого метода):

$$\ell_{W_{\mathbf{part}}}(\boldsymbol{\varphi}; \mathcal{B}) = -\frac{1}{|J_{\mathcal{B}^{\complement}}|} \sum_{j \in J_{\mathcal{B}^{\complement}}} \left( \ln f_{\boldsymbol{\xi}}(\omega_j; \boldsymbol{\varphi}) + \frac{I(\omega_j)}{f_{\boldsymbol{\xi}}(\omega_j; \boldsymbol{\varphi})} \right),$$

  где $\boldsymbol{\varphi}$ — вектор параметров шума $\boldsymbol{\xi}$, $f_{\boldsymbol{\xi}}$ — спектральная плотность шума $\boldsymbol{\xi}$, $I$ — периодограмма исходного ряда, $J_{\mathcal{B}^{\complement}} = \{j \in \{1, \ldots, m\} : \ \omega_j = j/N \notin \mathcal{B}\}$, $m = \lfloor (N-1)/2 \rfloor$.
- Далее под MC-SSA будет подразумеваться именно эта модификация.

# Глава 2. Методы автоматической идентификации компонент

# Введение

- После применения MC-SSA, если $H_0 : \mathrm{S} = 0$ отвергласъ, необходимо выделить значимый сигнал.
- Критерий MC-SSA с косинусами в качестве векторов для проекции не позволяет выделить сигнал.
- Однако, критерий дает информацию о значимых частотах, которую можно использовать.

# Обозначения и известные результаты: Автоматическая группировка в SSA

Для ряда X длины $N$ и $0 \leqslant \omega_1 \leqslant \omega_2 \leqslant 0.5$ определим меру [Алесандров, Голяндина, 2004]

$$T(\mathsf{X}; \omega_1, \omega_2) = \frac{1}{\|\mathsf{X}\|^2} \sum_{k:\omega_1 \leqslant k/N \leqslant \omega_2} \Pi(k/N),$$

где $\Pi$ — односторонняя периодограмма ряда X:

$$\Pi(k/N) = \begin{cases} I(k/N) + I(1 - k/N), & \text{для } 0 < k < N/2, \\ I(k/N), & \text{иначе.} \end{cases}$$

Величину $T(\mathsf{X}; \omega_1, \omega_2)$ можно рассматривать как долю вклада частот, содержащегося в интервале $[\omega_1, \omega_2]$.

# Обозначения и известные результаты: Автоматическая идентификация тренда [Александров, Голяндина, 2004]

**Алгоритм (Автоматическая идентификация тренда)**

*Входные данные: элементарные восстановленные компоненты* $\mathsf{X}^{(j)}$, $j \in J$, *порог низких частот* $\omega_0$, *порог вклада низких частот* $T_{low} \in [0, 1]$.

*Результат: компоненты, относящиеся к тренду, оценка тренда.*

1. *Вычислить* $T_j = T(\mathsf{X}^{(j)}; 0, \omega_0)$ *для каждого* $j \in J$.
2. *Определить компоненты* $J_{Trend} = \{j \in J : \ T_j > T_{low}\}$, *относящиеся к тренду, вычислить оценку тренда* $\hat{\mathsf{T}} = \sum\limits_{j \in J_{Trend}} \mathsf{X}^{(j)}$.

Алгоритм autoEOSSA [Golyandina, Dudnik, Shlemov, 2023]: применение переразложения EOSSA к первым $r$ компонентам и последующее применение алгоритма автоматической идентификации тренда.

# Автоматическая идентификация периодики: алгоритм

## Алгоритм (Автоматическая идентификация периодики)

*Входные данные*: *Ряды* $\mathsf{X}^{(j)}$, $j \in J$, *частота* $\omega \in (0, 0.5]$, *радиус* $\delta \geqslant 0$, *порог* $T_0 \in [0, 1]$, *количество компонент* $d$.

*Результат*: *Индексы рядов, относящихся к периодике с частотой* $\omega$, *оценка* $\hat{\mathsf{P}}$.

1. *Вычислить* $T_j = T(\mathsf{X}^{(j)}; \omega - \delta, \omega + \delta)$ *для каждого* $j \in J$.
2. *Из множества* $J_{signif} = \{j \in J : \ T_j > T_0\}$ *выбрать* $\min(d, |J_{signif}|)$ *элементов, соответствующих рядам с наибольшим* $\mathsf{MSS}\left(\mathsf{X}^{(j)}\right) = \frac{1}{N}\sum_{i=1}^{N}\left(x_i^{(j)}\right)^2$. *Обозначим множество этих индексов за* $J_{Periodic}$.
3. *Вычислить оценку периодики* $\hat{\mathsf{P}} = \sum\limits_{j \in J_{Periodic}} \mathsf{X}^{(j)}$.

# Автоматическая идентификация периодики: замечания

- В алгоритме ряды $\mathsf{X}^{(j)}$ не обязательно являются элементарно восстановленными компонентами. Это могут быть уже сгруппированные (например, с помощью метода регулярности углов [Жорникова, 2018]) ряды: в таком случае $d = 1$.
- Если $\mathsf{X}^{(j)}$ — элементарные восстановленные компоненты, то, учитывая, что экспоненциально-моделированная гармоника описывается одной или двумя компонентами, в качестве параметра $d$ логично взять

$$d_{\cos}(\omega) = \begin{cases} 2, & \text{для } \omega \in (0, 0.5), \\ 1, & \text{иначе.} \end{cases} \tag{1}$$

- Для применения метода необходимо знать сигнальную частоту $\omega$: ее можно получить с помощью метода MC-SSA.

# Обозначения и известные результаты: Метод регулярности углов [Жорникова, 2018]

- Что делает метод? Метод идентифицирует э-м гармоники с частотами $0 < \omega < \frac{1}{2}$.
- Входные данные и параметры: Левые сингулярные векторы траекторной матрицы. Порог $\tau_0$.
- Идея метода: Метод использует факт, что углы между последовательными отрезками на двумерной диаграмме сингулярных векторов равны.
- В работе [Дудник, 2025] метод расширен на случай $\omega = \frac{1}{2}$. К параметрам добавился порог $p_0$. Используется регулярность смены знака компоненты.

# Обозначения и известные результаты: Метод SSA-Aid [Дудник, 2025]

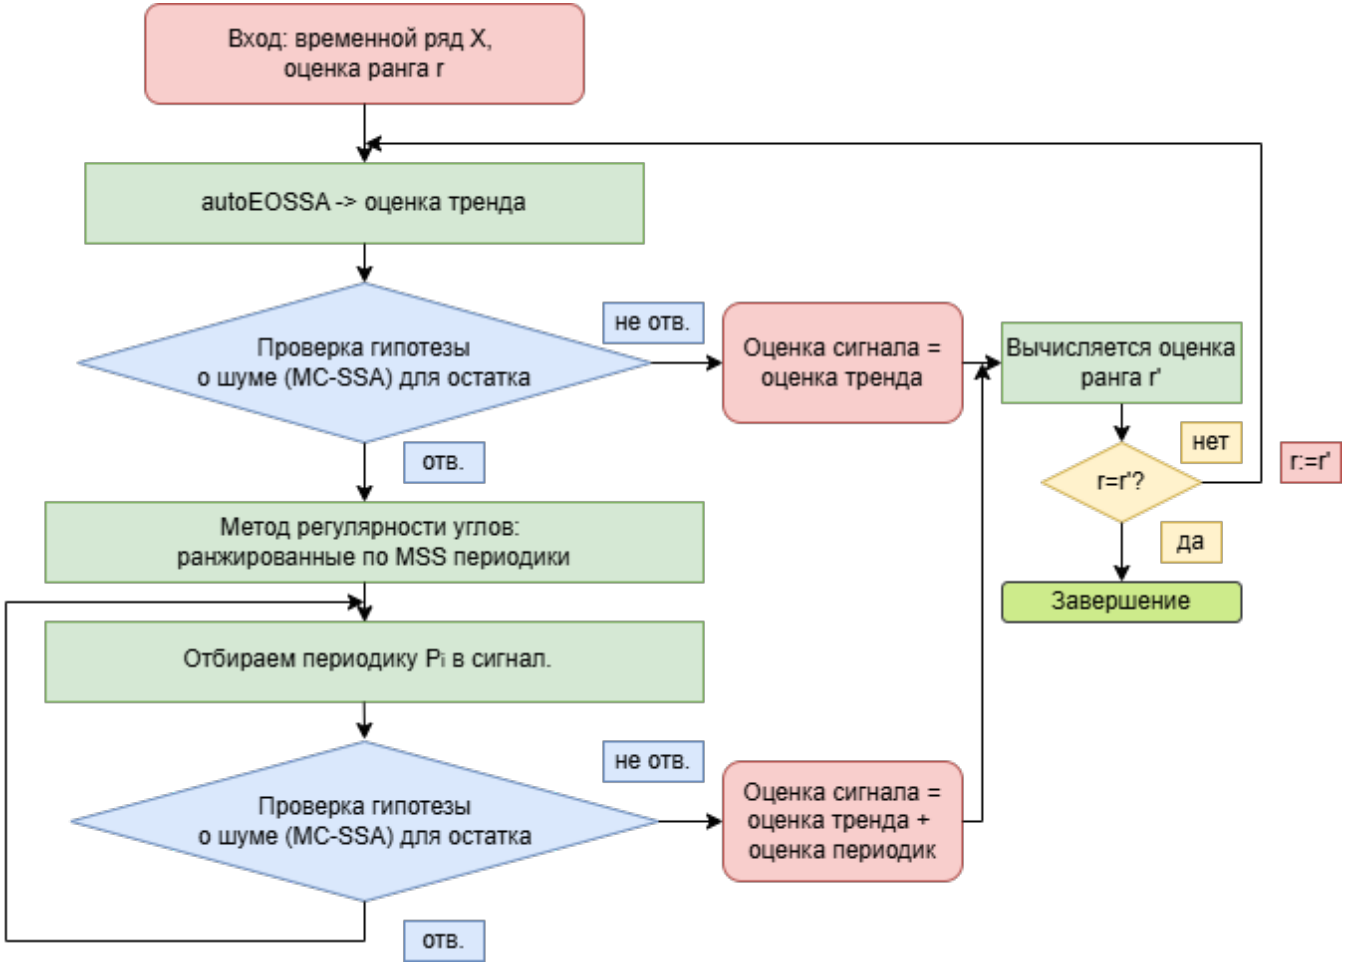


Рис.: Схема алгоритма SSA-Aid

# Недостатки метода SSA-Aid

SSA-Aid, хотя и является довольно мощным методом автоматической идентификации сигнала, обладает двумя критическими недостатками:

1. Метод использует критерий MC-SSA как хороший критерий проверки гипотезы об отсутствии сигнала в остатке и не использует информацию о значимых частотах, которые дает MC-SSA.
2. Если компоненты сигнала не доминируют перед шумом (то есть сначала идут сигнальные компоненты, включая трендовые, потом какое-то количество шумовых, а потом снова сигнальные) метод SSA-Aid не сможет их обнаружить, не захватив с собой шумовые компоненты.

Задача: разработать метод автоматической идентификации сигнала, который не имеет перечисленных недостатков.

# Мощность MC-SSA в случае сложного сигнала

Модель: $\mathsf{X} = \mathsf{S} + \boldsymbol{\xi}$, где $\mathsf{S} = (s_1, \ldots, s_N)$:

$$s_n = 2\cos\left(\frac{2\pi n}{4}\right) + \cos\left(\frac{2\pi n}{8}\right),$$

$N = 200$, $\boldsymbol{\xi}$ — красный шум с $\phi = 0.7$, $\sigma^2 = 1$.

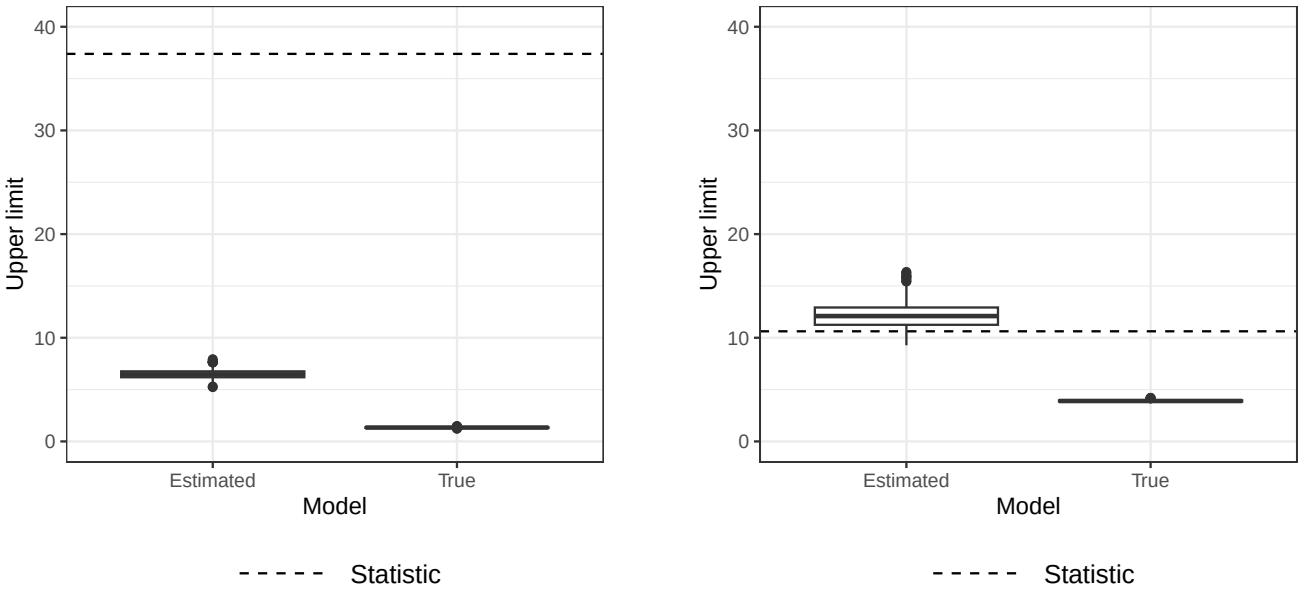


(a) $\omega = 0.25$ (b) $\omega = 0.125$

Рис.: Верхние границы предсказательных интервалов

# Мощность MC-SSA в случае сложного сигнала

- В случае истинной модели шума обе частоты являются значимыми всегда.
- Когда параметры шума оцениваются, более сильная часть сигнала ($\omega = 0.25$) все еще значима, в то время как более слабая часть ($\omega = 0.125$) перестает быть значимой в большинстве случаев.
- Проблема: при оцененных параметрах шума критерий MC-SSA может обнаружить не все частоты, принадлежащие сигналу.
- Решение: оценивать сигнал последовательно, применяя критерий MC-SSA к остатку до тех пор, пока гипотеза $H_0 : \mathsf{S} = 0$ не перестанет отвергаться.

# Метод autoMCSSA

## Алгоритм (autoMCSSA)

*Входные данные*: временной ряд $\mathsf{X}$, элементарные восстановленные компоненты $\mathsf{X}^{(j)}$, $j \in J$, длина окна $L \in (1, N)$, модель шума $\boldsymbol{\xi}$, уровень значимости $\alpha$, порог низких частот $\omega_0$, радиус $\delta \geqslant 0$, порог $T_0 \in [0, 1]$.

*Результат*: индексы периодических компонент $J_{\textbf{Periodics}}$, оценка периодик $\hat{\mathsf{P}}$.

1. Инициализировать оценку периодик $\hat{\mathsf{P}}$ нулевым рядом, множество индексов $J_{\textbf{Periodics}} := \varnothing$ и диапазоны нерассматриваемых частот $\mathcal{B} := [0, \omega_0]$.
2. Применить критерий MC-SSA к ряду $\mathsf{X}$. Если нулевая гипотеза не отвергается при уровне значимости $\alpha$, завершить работу алгоритма.
3. Если $|J| = 0$, завершить работу алгоритма.
4. Вычислить оценку максимально значимой частоты $\omega^\star$.
5. Получить компоненты $J_{\omega^\star}$ и оценку периодики $\mathsf{P}_{\omega^\star}$ с помощью алгоритма автоматической идентификации периодики с рядами $\left\{\mathsf{X}^{(j)}\right\}_{j \in J}$ и $d = d_{\cos}(\omega^\star)$.
6. $J_{\textbf{Periodics}} := J_{\textbf{Periodics}} \cup J_{\omega^\star}$, $\hat{\mathsf{P}} := \hat{\mathsf{P}} + \mathsf{P}_{\omega^\star}$, $\hat{\mathsf{N}} := \mathsf{X} - \hat{\mathsf{P}}$.
7. Если $|J_{\omega^\star}| = 0$, $\mathcal{B} := \mathcal{B} \cup [\omega^\star - \delta, \omega^\star + \delta]$.
8. Применить к остатку $\hat{\mathsf{N}}$ критерий MC-SSA. Если гипотеза не отвергается при уровне значимости $\alpha$, завершить работу алгоритма.
9. $J := J \setminus J_{\omega^\star}$, вернуться к шагу 2.

# Выбор оптимальных параметров autoMCSSA

- В случае неизвестного сигнала выбор параметров $\delta$ и $T_0$ проблематичен.
- Выбирать $\delta$ нужно в зависимости от величины амплитудной модуляции $C = |\alpha N|$.
- Были проведены численные сравнения различных подходов к выбору $\delta$ и $T_0$.
- Предлагается брать $T_0 \approx 0.5$ и вычислять «оптимальное» $\delta$, используя частичные суммы вокруг главной частоты $\omega$ сигнала S:

$$\Sigma^{C,\omega}(\delta) = \sum_{m:\ |\omega_{(k)}-\omega|\leqslant\delta} \tilde{\Pi}^{C,\omega}\left(\omega_{(m)}\right), \quad n = 0, \ldots, \lfloor N/2 \rfloor,$$

где $\tilde{\Pi}(k/N) = \Pi(k/N)/\sum_k \Pi(k/N)$ — нормированная (односторонняя) периодограмма.

# Алгоритм выбора радиуса частотного интервала

**Алгоритм (Выбор радиуса частотного интервала при заданной границе величины амплитуднои модуляции)**

*Входные данные*: *Длина ряда* $N$, *частота* $\omega$, *верхняя граница величины амплитудной модуляции* $C_{\max}$, *порог* $\Sigma_t$, *порог приращения* $\varepsilon$.

*Результат*: *Радиус частотного интервала* $\delta^*$.

1. *Ранжировать* $\{k/N\}_{k=0}^{\lfloor N/2 \rfloor}$ *по величине* $|\omega - k/N|$, $\omega_{(k)}$ — *полученный набор.*
2. *Если* $\omega N$ — *целое*, $\delta_0 := 0$, *иначе* $\delta_0 := |\omega - \omega_{(2)}|$.
3. *Для* $n = 1, \ldots, \lfloor N/2 \rfloor$ *вычислить* $\delta_n = \delta_0 + n/N$.
4. *Для* $n = 0, \ldots, \lfloor N/2 \rfloor$ *вычислить* $\Sigma_n^{C_{\max},\omega} = \Sigma^{C_{\max},\omega}(\delta_n)$.
5. *Найти такое первое* $n = n^*$, *что* $\Sigma_{n^*}^{C_{\max},\omega} > \Sigma_t$ *и* $\Sigma_{n^*}^{C_{\max},\omega} - \Sigma_{n^*-1}^{C_{\max},\omega} < \varepsilon$, $\delta^* := \delta_{n^*}$.

# Алгоритм выбора радиуса частотного интервала: Пример

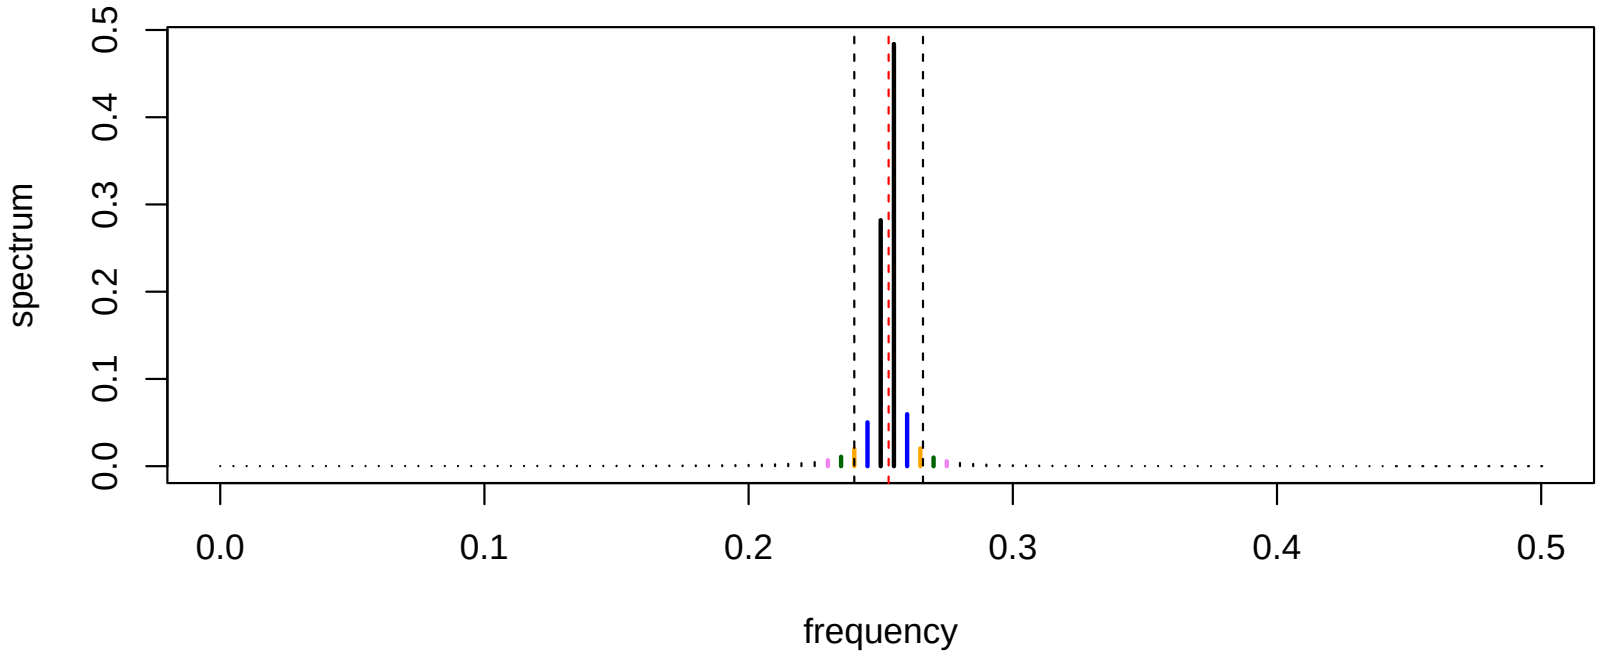


Рис.: $\Pi^{C,\omega}(k/N)$ и границы частотного интервала при $\delta = \delta^*$ ($N = 200$, $C = 2$, $\omega = 0.253$, $\Sigma_t = 0.9$, $\varepsilon = 0.05$)

# Метод autoMCSSA: преимущества и недостатки

- Основное преимущество: Метод позволяет выделять сигнал, компоненты которого в SSA разложении не обязательно доминируют.
- Недостаток: Если компоненты в SSA разложении неразделимы (это так, например, в случае гармоник с одинаковыми амплитудами), то описанный способ автоматической группировки перестает работать.
- Идея: использовать метод после метода SSA-Aid, чтобы выделить компоненты, которые смешались с шумом.

# Модификация отбора гармоник в методе SSA-Aid

Вместо последовательного выделения гармоник с наибольшей суммой квадратов, можно подойти более умно, используя преимущество MC-SSA перед другими критериями проверки ряда на наличие сигнала: информацию о значимой частоте.

**Алгоритм (Модификация отбора гармоник в методе SSA-Aid)**

*Входные данные: сгруппированные методом регулярности углов гармоники* $\{\mathsf{X}^{(j)}\}_{j\in J_{\textbf{Periodics}}}$*, оценка максимально значимой частоты* $\omega^\star$*, порог* $T_0$*, верхняя граница величины амплитудной модуляции* $C_{max}$*.*

*Результат: множество* $J_{\omega^\star}$ *индексов, соответствующей частоте* $\omega^\star$*, оценка периодики* $\mathsf{P}_{\omega^\star}$*.*

1. *Вычислить радиус* $\delta^*_{\omega^\star} = \delta^*(\omega^\star, C_{max})$*.*
2. *Получить множество* $J_{\omega^\star}$ *и оценку периодики* $\mathsf{P}_{\omega^\star}$ *с помощью алгоритма автоматической идентификации гармоник с рядами* $\{\mathsf{X}^{(j)}\}_{j\in J_{\textbf{Periodics}}}$*,* $\delta = \delta_{\omega^\star}$ *и* $d = 1$*.*

# Метод SSA-AidMC

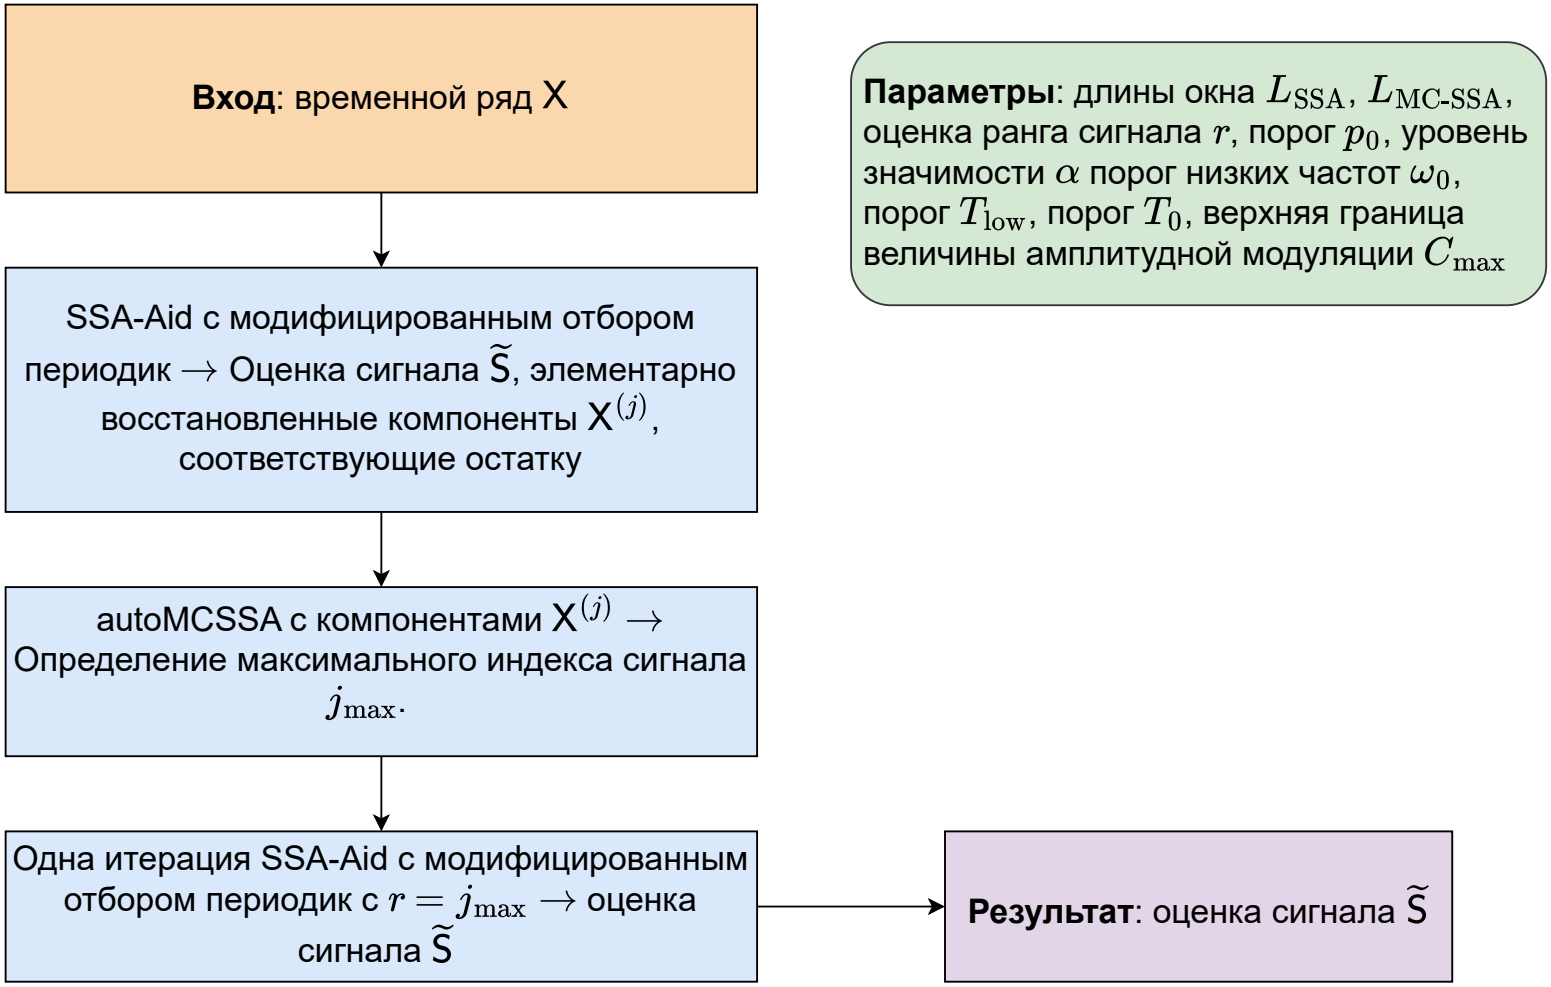


Рис.: Схема алгоритма SSA-AidMC

# Численное сравнение точности идентификации компонент

Модель: $\mathsf{X} = \mathsf{T} + \mathsf{P} + \boldsymbol{\xi}$, где $N = 200$, $\mathsf{T} = (t_1, \ldots, t_N)$ — тренд, $\mathsf{P} = (p_1, \ldots, p_N)$, $\boldsymbol{\xi}$ — красный шум с параметрами $\phi$ и $\sigma^2$.

Задача: сравнить методы autoMCSSA, SSA-Aid и SSA-AidMC по точности выделения различных сигналов.

**Замечание**

*Метод autoMCSSA умеет работать только с периодичностью. Однако можно сначала применить алгоритм autoEOSSA [Golyandina, Dudnik, Shlemov and 2023] для выделения тренда, а потом применять autoMCSSA к остатку и с нетрендовыми элементарными компонентами.*

# Численное сравнение точности идентификации компонент: сигнал доминирует над шумом

Рассмотрим примеры сигналов, доминирующих над шумом. Для таких сигналов выбраны следующие параметры алгоритмов:

1. Длины окна $L_{\text{SSA}} = 96$ и $L_{\text{MC-SSA}} = 48$;
2. Порог низких частот $\omega_0 = 1/24$;
3. Пороги $T_{\text{low}} = T_0 = 0.5$;
4. Максимально возможная модуляция $C_{\max} = 5$;
5. Оценка ранга сигнала $r = 30$.

Также рассмотрим два случая параметра $\phi$: $\phi = 0$ (белый шум) и $\phi = 0.3$. Дисперсия белого шума $\sigma^2 = 1$ в обоих случаях.

# Численное сравнение точности идентификации компонент: сигнал доминирует над шумом

Пример 1:

$$t_n = 0.2e^{0.025n} + 2\cos\left(\frac{2\pi n}{60}\right),$$

$$p_n = 4.12\cos\left(\frac{2\pi n}{4}\right) + 4.12\cos\left(\frac{2\pi n}{3}\right) + 6\cdot(-1)^n.$$

Таблица: MSE восстановления сигнала, пример 1

| Метод | Компонента | Mean MSE | Median MSE |
|---|---|---|---|
| SSA-AidMC | Тренд | 0.04372 | 0.03652 |
| | Периодика | 0.07700 | 0.06915 |
| | Сигнал | 0.12059 | 0.11141 |
| autoMCSSA | Тренд | 0.063695 | 0.056327 |
| | Периодика | 0.15735 | 0.07171 |
| | Сигнал | 0.22069 | 0.14024 |
| SSA-Aid | Тренд | 0.04361 | 0.03652 |
| | Периодика | 0.07146 | 0.06594 |
| | Сигнал | 0.11494 | 0.10880 |

(a) Белый шум ($\sigma^2 = 1$)

| Метод | Компонента | Mean MSE | Median MSE |
|---|---|---|---|
| SSA-AidMC | Тренд | 0.10714 | 0.09391 |
| | Периодика | 0.05788 | 0.04978 |
| | Сигнал | 0.16477 | 0.15293 |
| autoMCSSA | Тренд | 0.17468 | 0.15858 |
| | Периодика | 0.18239 | 0.05296 |
| | Сигнал | 0.35553 | 0.22301 |
| SSA-Aid | Тренд | 0.10617 | 0.09265 |
| | Периодика | 0.05377 | 0.04891 |
| | Сигнал | 0.15968 | 0.14524 |

(b) Красный шум ($\phi = 0.3$, $\sigma^2 = 1$)

# Численное сравнение точности идентификации компонент: сигнал доминирует над шумом

Пример 2:

$$t_n = 0.2e^{0.025n} + 2\cos\left(\frac{2\pi n}{60}\right),$$

$$p_n = 4e^{-0.01n}\cos\left(\frac{2\pi n}{4}\right) + 4\cos\left(\frac{2\pi n}{3}\right) + 6e^{-0.01n}\cdot(-1)^n.$$

Таблица: MSE восстановления сигнала, пример 2

| Метод | Компонента | Mean MSE | Median MSE |
|---|---|---|---|
| SSA-AidMC | Тренд | 0.04372 | 0.03652 |
| | Периодика | 0.07700 | 0.06915 |
| | Сигнал | 0.12059 | 0.11141 |
| autoMCSSA | Тренд | 0.066280 | 0.053641 |
| | Периодика | 0.08458 | 0.07197 |
| | Сигнал | 0.1346 | 0.1261 |
| SSA-Aid | Тренд | 0.043611 | 0.036592 |
| | Периодика | 0.07146 | 0.06705 |
| | Сигнал | 0.1150 | 0.1087 |

(a) Белый шум ($\phi = 0$, $\sigma^2 = 1$)

| Метод | Компонента | Mean MSE | Median MSE |
|---|---|---|---|
| SSA-AidMC | Тренд | 0.10714 | 0.09391 |
| | Периодика | 0.05788 | 0.04978 |
| | Сигнал | 0.16477 | 0.15293 |
| autoMCSSA | Тренд | 0.14453 | 0.12942 |
| | Периодика | 0.06520 | 0.05408 |
| | Сигнал | 0.19250 | 0.18189 |
| SSA-Aid | Тренд | 0.10608 | 0.09286 |
| | Периодика | 0.05360 | 0.05103 |
| | Сигнал | 0.15936 | 0.14650 |

(b) Красный шум ($\phi = 0.3$, $\sigma^2 = 1$)

# Численное сравнение точности идентификации компонент: шум доминирует над некоторыми компонентами сигнала

Рассмотрим примеры сигналов, некоторые компоненты которых не доминируют над шумом. Для таких сигналов выбраны следующие параметры алгоритмов:

1. Длины окна $L_{\text{SSA}} = 96$ и $L_{\text{MC-SSA}} = 48$;
2. Порог низких частот $\omega_0 = 1/24$;
3. Пороги $T_{\text{low}} = T_0 = 0.5$;
4. Максимально возможная модуляция $C_{\max} = 5$;
5. Оценка ранга сигнала $r = 30$;
6. Поскольку шум будет достаточно сильным, порог для алгоритма SSA-Aid $t_0 = 0.5$, а для алгоритма SSA-AidMC $t_0 = +\infty$ (то есть его нет).

Будем рассматривать красный шум с параметрами $\phi = 0.7$ и $\sigma^2 = 1$.

# Численное сравнение точности идентификации компонент: шум доминирует над некоторыми компонентами сигнала

Пример 3:

$$p_n = 0.075e^{0.02n}\cos\left(\frac{2\pi n}{8}\right) + \cos\left(\frac{2\pi n}{4}\right) + 0.2\cdot(-1)^n.$$

Таблица: MSE восстановления сигнала, пример 3 ($\phi = 0.7$, $\sigma^2 = 1$)

| Метод | Mean MSE | Median MSE |
|---|---|---|
| SSA-AidMC | 0.10954 | 0.08997 |
| autoMCSSA | 0.15317 | 0.11806 |
| SSA-Aid | 0.62960 | 0.53496 |

# Численное сравнение точности идентификации компонент: шум доминирует над некоторыми компонентами сигнала

Пример 4:

$$p_n = 0.075e^{0.02n}\cos\left(\frac{2\pi n}{8}\right) + 1.5e^{-0.01n}\cos\left(\frac{2\pi n}{4}\right) + e^{-0.01n}\cdot(-1)^n.$$

Таблица: MSE восстановления сигнала, пример 4 ($\phi = 0.7$, $\sigma^2 = 1$)

| Метод | Mean MSE | Median MSE |
|---|---|---|
| SSA-AidMC | 0.11023 | 0.09082 |
| autoMCSSA | 0.14604 | 0.11728 |
| SSA-Aid | 0.84790 | 0.75026 |

# Численное сравнение точности идентификации компонент: выводы

Можно сделать следующие выводы:

- В случае доминирующего над шумом сигнала метод SSA-AidMC немного хуже метода SSA-Aid.
- В случае же сигналов, у которых некоторые компоненты не доминируют над шумом, SSA-AidMC является безоговорочным лидером. По ошибке восстановления сигнала метода SSA-Aid можно прийти к выводу, что он в данном случае неприменим.
- autoMCSSA показывает в обоих случаях результат хуже, чем SSA-AidMC в виду проблемы неразделимости компонент.

# Заключение

Мои результаты:

1. Метод MC-SSA был обобщен на временные ряды с длинной памятью.
2. Были разработаны и реализованы методы autoMCSSA и SSA-AidMC автоматической идентификации компонент, использующие критерий MC-SSA для определения значимых частот.
3. На основании численных экспериментов были сделаны следующие выводы:
   - Для оценки параметров шума предпочтительнее использовать метод Уиттла ввиду его меньшей трудоемкости и меньшего смещения оценок при неизвестном среднем.
   - Критерий MC-SSA с косинусами в качестве проекционных векторов предпочтительнее критерия с векторами, порожденными исходным рядом. Такой выбор векторов избавляет от проблемы радикальности критерия с сохранением мощности.
   - Метод SSA-AidMC показал себя намного лучше метода SSA-Aid в случае, когда сигнал не обязательно доминирует над шумом. С случае же, когда он доминирует, точность идентификации становится не сильно хуже.

# Дальнейшие планы

1. Добавить больше примеров рядов с длинной памятью.
2. Провести больше сравнений SSA-AidMC с другими алгоритмами, в том числе на реальных данных.